EvoTrace：通过反思压缩持续演化的树状种群

匿名作者

摘要

自动算法设计中的受评程序具有两种价值：作为后续搜索的开发起点，以及为后续修改提供设计经历。一个程序可能不再值得继续开发，其经历却仍有参考价值。本文提出 EvoTrace，将种群更新与搜索经历的反思压缩结合。EvoTrace 维护由可执行候选、派生关系与凝练经验组成的树状种群。一次保留决策同时确定哪些程序保持显式形式、哪些历史区域需要凝练，以及哪些保留位置承接经验。被收缩路径及其同轮移除旁支的经历进入重连边，其余被剪旁支的经历进入保留祖先。后续简化继续交接已有经验，改进、交叉与探索则读取同一结构的不同视图。EvoTrace 由此将种群组织为可用程序与设计历史共同演化的表示，通过选择与反思联合决定过去的评价如何继续参与未来搜索。

1. 引言

大语言模型（large language model，LLM）通过程序生成、评价与修改，使自动算法设计（automated algorithm design, AAD）成为持续迭代的程序搜索过程 [Romera-Paredes et al., 2024, Liu et al., 2024, Lehman et al., 2022]。在有限评价预算下，每次尝试产生两种有用材料：一个可执行候选，以及关于某项计算选择的比较证据。候选为后续搜索提供起点，相对父代的比较为下一次修改提供参考。搜索需要持续决定开发哪些实现，以及将哪些经历带入新的设计。

这两项决策面对不同的价值判断。一个程序可能已经被更好的后代取代，但沿途的修改和替代尝试仍有参考价值。一次退步尝试可能不是理想的开发起点，其结果却能帮助理解后来对父代的修改。因此，候选保留与经验保留不必选择相同的材料。核心问题是：**当可执行成员不断变化时，种群如何持续积累可供利用的设计经验?**

现有搜索状态提供了多种组织方式。演化种群维护可用于变异的候选 [Romera-Paredes et al., 2024, Liu et al., 2024, Hu and Zhang, 2025]；反思方法将评价转为语言反馈 [Ye et al., 2024]；记忆方法组织跨修改、跨分支的经验 [Jiang et al., 2026, Haji et al., 2026]；树与谱系方法保存派生关系，用于选择、生成与剪枝 [Zheng et al., 2025, Gungordu et al., 2026, Zhao et al., 2026]。这些研究说明候选竞争与发展背景均可参与算法搜索，本文聚焦连接两项决策的更新操作：由保留候选结构共同确定经历压缩的范围及位置。

本文将种群更新视为对搜索历史表示的选择。部分实现继续以程序形式存在，供搜索进一步开发；相关历史则可以转为凝练经验。**反思完成这一压缩，树状种群为压缩提供范围与位置**。树将可执行候选之间的竞争与连接其发展的派生关系结合起来。确定保留候选后，同一结构就能识别它们之间的中间历史及周围的替代分支，从而确定需要凝练的材料及结果的承接位置。

我们据此提出 **EvoTrace**，以**动态反思简化**维护带经验的树状种群。每次更新先选择质量代表与近期开发的实现，再保留连接它们所需的分叉。被移除的中间版本及其旁支尝试凝练为重连边上的经验，其余被移除分支凝练为保留祖先上的经验。当后续更新简化经验的载体时，已有经验随之交接。后续生成从维护后的树中同时获取起始程序与相关经历。

一次保留决策共同确定留下的候选、需要压缩的区域及其承接位置，在选择与经验积累之间建立结构联系：每个移除区域都有确定的保留承接位置。父代采样随后分配评价机会，算子视图为改进提供局部发展、为交叉提供两条发展路径、为探索提供路线思想。

本文提出两项相互配合的贡献：

1. **带经验的树状种群**。将可执行候选、派生关系与凝练后的设计经验组织于同一演化结构，使当前种群同时提供开发起点及其相关历史。
2. **动态反思简化**。将种群更新与经历压缩结合，由保留结构共同确定历史整理范围和经验承接节点或边，使退出

种群的尝试与后续生成保持联系。

2. 相关工作

程序演化与候选竞争。遗传编程演化可执行程序 [Koza, 1994]，超启发式与算法配置分别搜索启发式组件和求解器设置 [Burke et al., 2013, López-Ibáñez et al., 2016]。LLM 驱动的 AAD 将变异扩展到程序生成与修改 [Liu et al., 2026]。Evolution through Large Models 使用代码模型进行变异 [Lehman et al., 2022]，语言模型交叉重组文本基因型 [Meyerson et al., 2024]。FunSearch 将程序生成与岛屿种群结合 [Romera-Paredes et al., 2024]；EoH 共同演化启发式思想与实现 [Liu et al., 2024]；LLaMEA 与 AlphaEvolve 进一步发展评价驱动的算法和代码演化 [van Stein and Bäck, 2025, Novikov et al., 2025]。和声搜索 [Dat et al., 2025]、生态位 [Hu and Zhang, 2025] 与结合质量和使用次数的父代采样 [Lange et al., 2026] 分别处理多样性和开发分配。EvoTrace 适配后一类采样，并将候选维护与相关设计历史的压缩联系起来。

算法搜索中的派生结构。 MCTS-AHD 使用搜索树及树路径推理生成启发式 [Zheng et al., 2025]。Clade-AHD 将后代评价聚合为分支级选择的信念 [Lai et al., 2026]。PathWise 结合外层种群与内层蕴含图，协调规划、生成与反思 [Gungordu et al., 2026]。PhyloEvolve 维护谱系森林、精英池、轨迹生成上下文及结构剪枝，其 Summarizer 定期凝练轨迹，并按语义相似度检索摘要 [Zhao et al., 2026]。这些方法将当前候选与其派生过程联系起来。EvoTrace 利用保留派生结构定义联合更新：路径收缩与旁支剪除确定反思区域，摘要保存在承接相关经历的保留连接或祖先上。

反思与经验复用。Self-Refine 通过自反馈持续修改输出 [Madaan et al., 2023]；Reflexion 与 ExpeL 保存跨尝试的语言经验 [Shinn et al., 2023, Zhao et al., 2024]。在 AAD 中，ReEvo 结合短期比较和长期反思 [Ye et al., 2024]；RefineEvo 利用规划及正负经验 [Wu et al., 2026]；MeEvo 交替执行种群演化与共享历史反思 [Qiu et al., 2026]。DeltaEvolve 在层次上下文系统中组织语义修改记录 [Jiang et al., 2026]。MEMOIR 结合分支局部记忆与分支结束时凝练的摘要 [Haji et al., 2026]。EvoTrace 由候选维护所使用的同一保留结构确定反思范围及位置，并通过递归交接，使经验在原始实现退出在线种群后继续成为该结构的一部分。

3. 方法

3.1. 问题定义与总体过程

给定任务接口，候选程序需要实现完整求解器使用的指定函数。评价器在固定搜索数据集上执行程序，返回适应度或失败反馈。全文采用适应度越小越好的约定。搜索最多使用 B 次程序评价，执行失败和修复重评均计入预算。生成、修复与反思的模型请求分别核算。

EvoTrace 维护显式树状种群与完整尝试档案。树提供可选算法和生成上下文；档案保存程序、评价及种群更新。每轮选择算法、生成并评价候选、接入最终受评版本，再简化更新后的种群。搜索返回完整档案中搜索适应度最好的可行程序，同分取生成较早者。独立测试在该选择完成后进行。

3.2. 树状种群

记当前树为 $T = (\mathcal{N} \cup \{r\}, \mathcal{E})$，其中 r 是不包含实现的虚拟根。算法节点保存代码、计算过程描述、适应度 $f(v)$ 或失败反馈，以及实际使用记录。每个节点只有一个主父代。Crossover 另存参考算法来源，该来源不增加第二条结构边。全部保留的可行节点都可继续开发，内部节点与叶节点使用相同资格。

树保存两类经验。节点上的**选择经验**（selection experience）S_v 凝练归属该位置的已移除旁支；边上的**变异经验**（variation experience）V_{uv} 凝练保留端点之间被收缩的发展过程及中间节点的同轮移除旁支。两个名称对应产生摘要的简化操作。两类经验都可描述改进、同分、退步或失败，收缩路径也可包含净退步。选择经验进入生成上下文与后续反思，父代采样则使用适应度和开发次数。虚拟根可以承接退出显式种群的初始路线经验。普通边表示一次生成尝试，收缩边明确标为一个发展阶段。

初始化与 Explore 开启开发路线，Refine 与 Crossover 继承主父代路线。路线按实现的 Init/Explore 起点分组。原始入口被移除后，后代仍保存路线编号。路线用于父代分配和局部上下文组织。Explore 入口可以收缩；两端路线不同的重连边保留 Explore 类型。

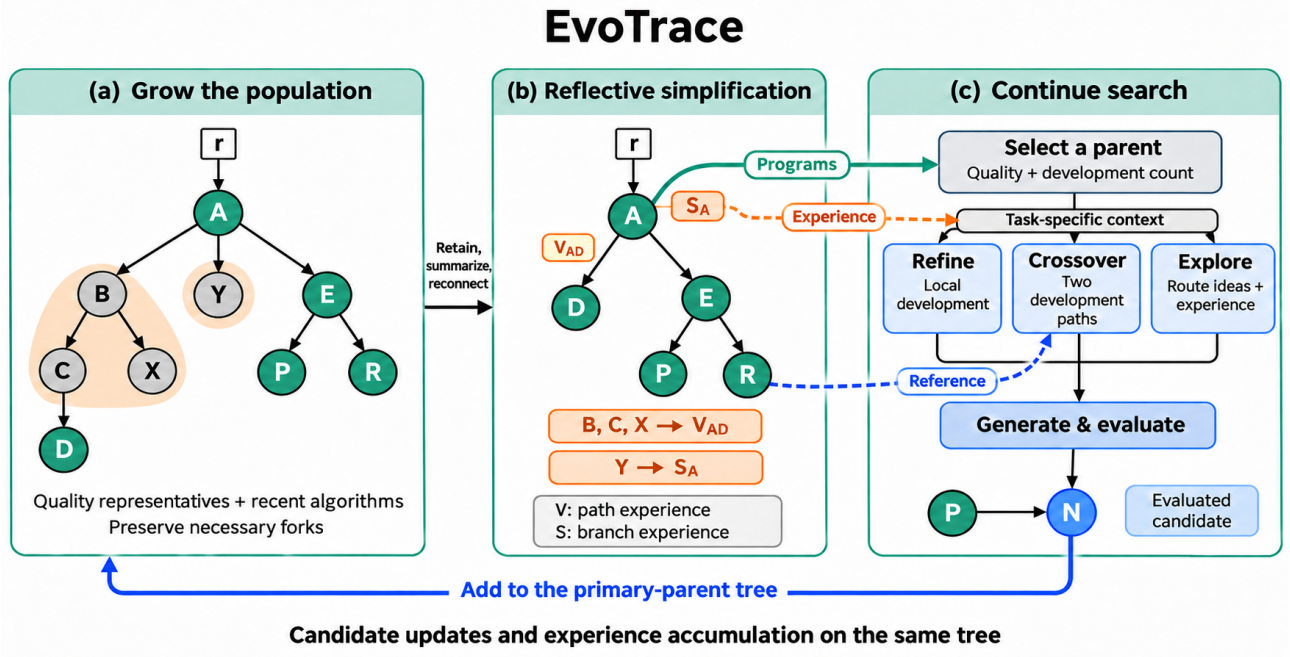


图 1: EvoTrace 整体框架。保留集合决定种群怎样简化，以及移除经历在哪里凝练为经验。更新后的树提供可选程序与适合当前设计任务的经验。每次尝试选择一种算子，受评候选随后接入主父代树。虚线表示经验与交叉参考等信息输入。

3.3. 动态反思简化

初始化完成后，每次有受评实现入树，系统执行三个步骤：选择算法、保留必要分叉、划分移除区域。三个步骤均基于同一份简化前快照。

选择质量代表。设 $\mathcal{P} \subseteq \mathcal{N}$ 是可行节点集合，按适应度和生成先后排序。节点的秩质量为

$$q(v) = 1 - \frac{\mathrm{rank}(v)}{\max(1, |\mathcal{P}| - 1)}, \qquad v \in \mathcal{P}, \tag{1}$$

最优节点的排名为 0。系统必留冠军，再按排名检查 $q(v) \geq 0.50$ 的候选。仅当同路线后代的适应度严格更好时，候选被标为已超越，不进入质量代表集合。该候选仍可因近期使用或必要分叉保留；若被移除，其经历按最终保留集合确定的区域交接。若候选与已有质量代表的标准化源码相同，或抽象语法树（abstract syntax tree, AST）距离小于 0.08，则视为已被覆盖。两者适应度相差不超过 10^{-9} 时，距离门槛为 0.20。未被覆盖的候选进入质量代表集合 $\mathcal{R}$。参与覆盖判断的已有代表，其适应度不差于当前候选。

结构距离是 AST 父子类型特征与遍历二元组的多重集 Jaccard 距离。特征保留运算类型、被调用函数名和控制结构，普通变量身份及数值取值不作为取值特征。标准化源码相同是独立判据，保留变量与常数，只忽略排版、注释和文档字符串。两种判据共同构成实现中的覆盖启发式。

保留近期使用算法。评价时钟 t 按实际程序评价推进。可行节点的最近使用时刻 $u(v)$ 在出生时刷新；作为 Refine/Crossover 主父代产生受评尝试时刷新。Explore 和只读交叉参考均不刷新原节点时钟。记 $p(v)$ 为 v 在树上的父代，近期集合为

$$\mathcal{U} = \{v \in \mathcal{P} : t - \max(u(v), u(p(v))) < W\}, \qquad W = 40, \tag{2}$$

其中父代为虚拟根或属于其他路线时只取 $u(v)$。同路线尝试可以共同失去近期资格；质量代表与必要分叉仍保留。

失败执行与修复重评均推进时钟。仅在提示中展示节点，或为了结构连接而保留节点，不刷新时间。近期保留维持窗口内的开发资格，实际开发机会仍由父代采样决定。

保留必要分叉。最终保留集合为

$$\mathcal{K} = \{r\} \cup \mathcal{R} \cup \mathcal{U} \cup \mathrm{LCA}(\mathcal{R} \cup \mathcal{U}), \tag{3}$$

其中，LCA(A) 表示 A 内节点两两最近共同祖先（lowest common ancestor, LCA）的集合，保留连接已选节点所需的分叉。未被选中且不承担这些分叉的中间祖先可以收缩。质量代表先选定，再加入近期节点和必要连接。因此，仅因近期性或连接职责而保留的节点，不会排斥更好的质量代表。一次更新只计算一次排名和代表集合。保留规模由最近使用、质量差异与分叉结构共同形成，规则不设固定容量。

联合划分路径与旁支。对每个保留算法，在原树上寻找最近保留祖先，两者之间被移除的中间节点组成路径收缩区域。其余移除节点向上寻找首个不属于旁支移除集合的祖先：若它是被收缩中间节点，旁支并入该路径区域；若是保留节点或虚拟根，则由其承接旁支区域。每个移除节点在本轮维护中只属于一个区域，同一承接位置的多条旁支合并处理。

同次更新可以缩短路径并剪除其旁支。例如，原树为 $A \to B \to C \to D$，另有 $B \to X$ 和 $A \to Y$，只保留 A, D 时，B, C 进入收缩路径，X 也进入该路径区域，共同凝练到 V_{AD}；旁支 Y 更新 A 处的 S_A。早先已附着于 B, C 的经验随原承载节点进入路径区域。

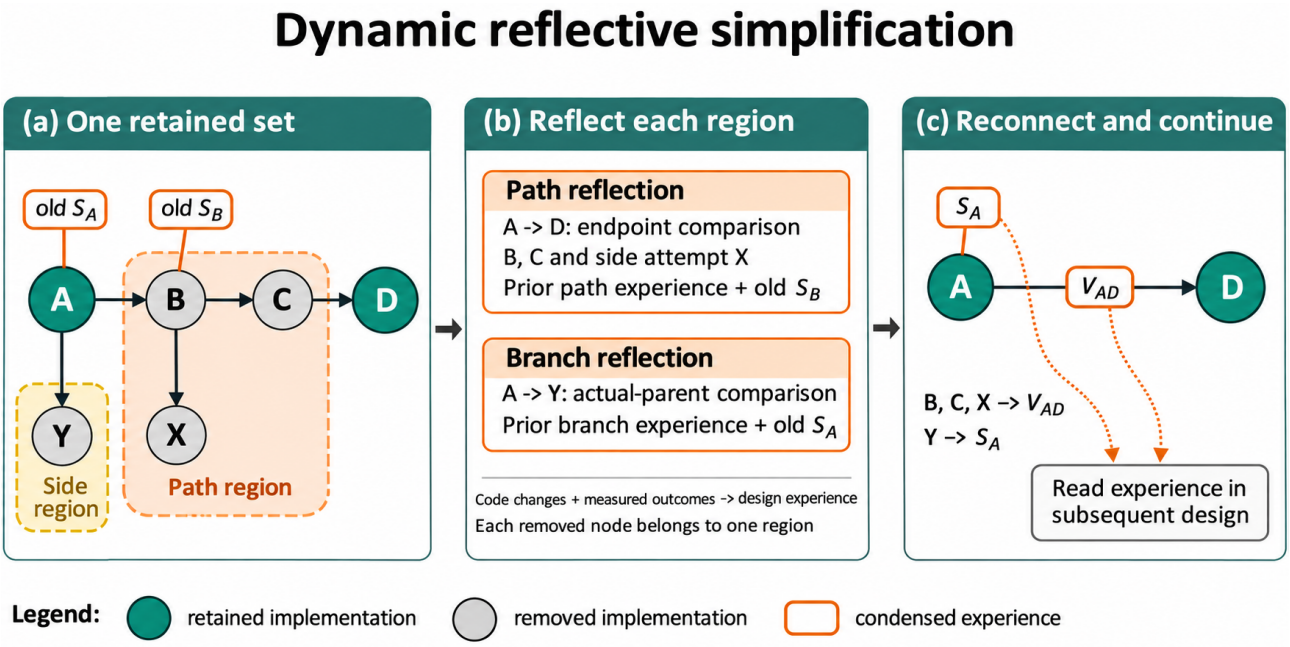


图 2: 经验随保留结构交接。保留 A 和 D 时，中间版本 B、C 及旁支 X 组成同一路径区域，凝练为重连边上的 V_{AD}；另一旁支 Y 更新 S_A。旧经验随承载位置交接：原 S_B 进入路径摘要，原 S_A 与 Y 的经历合并。

3.4. 区域反思

按区域反思。每个最终路径区域与每组旁支区域各调用一次反思。路径反思读取保留端点代码、端点净差分、中间受评实现及其结果、同轮移除旁支，以及区域内已有的节点和边经验。旁支反思读取承接位置的实现（若存在）、移除尝试相对各自真实父代的差分、评价或错误反馈，以及相关旧经验。虚拟根没有算法实现时，以任务级起点提供上下文。已经收缩的输入明确作为发展阶段展示。旁支比较使用每次尝试的实际父代。当前比较以程序计算的结果标签提供给反思模型；原始分数保留在日志，路径经验的端点分数由程序附加。两类反思均区分 Explore 初稿与局部修改，将每次观察结果归于具体受评实现。

反思提示要求简洁描述所尝试的计算及其观察结果，并在证据支持时给出可能解释。提示区分整段起终点的净变化与中间比较，将共同修改的部件作为组合改动处理。提示要求模型保留与当前测量比较一致的旧经验；比较标签本

身由程序计算。生成时的设计理由不进入证据。同次更新中的各区域读取同一原始快照，本轮新摘要不在同轮再次使用。

路径反思更新重连边上的 V_{uv}。旁支反思更新承接位置的 S_u，并吸收该位置原有的选择经验。后续更新若移除经验载体，累计经验继续归入新的对应区域。该递归过程使中间实现退出显式种群后，发展过程仍有凝练表示。树中摘要与保留实现共同提供发展上下文，尝试档案保存完整原始证据。

3.5. 从维护后的树继续搜索

父代与参考选择。 EvoTrace 适配 ShinkaEvolve 的加权父代采样 [Lange et al., 2026]。记 $D(v)$ 为节点 v 按原始 Init/Explore 路线编号归属的路线；每条非空路线只包含当前保留可行节点。定义

$$w(v) = \sigma\left(10\frac{m - f(v)}{s}\right)\frac{1}{1 + c(v)}, \tag{4}$$

$$P(D) \propto \max_{u \in D} w(u), \qquad P(v \mid D) = \frac{w(v)}{\sum_{u \in D} w(u)}, \tag{5}$$

其中，σ 为 sigmoid 函数，$c(v)$ 为使用 v 作为主父代的受评 Refine/Crossover 尝试数。每次采样前在当前树上重算质量代表，以其适应度中位数 m 及中位数绝对偏差尺度 s 进行归一化。全部保留可行节点均可参与采样，概率为 $P(D(v))P(v \mid D(v))$。固定权重时，加入一个不超过所属路线最大权重的版本，不改变路线概率。实际更新仍可通过新的最大值、父代进一步开发或代表集合及其归一化的变化，改变路线概率。

选定主父代后，系统以 0.45、0.25、0.30 的概率分别选择 Refine、Crossover 和 Explore。Crossover 先排除主父代和标准化源码重复项，再在实际可用参考中计算秩质量，保留不低于 0.30 的候选。系统优先考虑尚未使用的有序“主父代—参考” 配对，并在其中选择 AST 距离最大者；同距离时依次取适应度较好、生成较早者。合格配对全部使用过后允许复用；没有合格参考时执行 Refine。

按设计任务组织上下文。三个算子读取同一种群的不同视图：

算子	结构上下文	当前设计任务
Refine	当前代码与成绩；本路线形成路径及直接来源摘要；节点选择经验；可见出边尝试或发展阶段	结合形成过程和已评价替代尝试修改当前计算
Crossover	两份实现；同路线的共同祖先与双支，或跨路线各自的局部发展与来源摘要；相关节点和边经验；主父代的可见子尝试	决定迁移哪些计算以及怎样融合
Explore	不同路线的入口思想；所选路线中生成次序最新的保留版本；节点、边和根经验；一份已有实现	构造主要计算方式不同的替代算法

普通转移展示相对真实父代的差分和结果，收缩转移展示端点结果和累计变异经验。差分序列提供解释变化所需的基准代码。同路线 Crossover 只展示一次共同祖先；跨路线时简述历史来源，不展开旧路线。Explore 不在每段经验前重复完整设计描述。Explore 先组织思想与经验，再给出一份现有实现，使模型可以重新考虑表示或计算过程。

上下文构造先组织相关保留材料。若生成提示超过输入预算，系统依据实际释放的 token 数量，减少完整路径条目、尝试条目或路线条目。当前源码、参考源码及解释差分所需的基准保持可用。输入适配只改变单次提示视图，不改变树、保留决策或经验归属。每个算子返回完整实现及其计算过程描述。

3.6. 搜索过程

算法 1 给出完整过程。初始化在同一预算内获得五个可行程序。每次生成尝试最多允许一次修复，并最多贡献一个最终受评节点。修复重评另计评价预算。没有产生程序评价的尝试不入树，也不推进评价时钟。

```
算法 1：EvoTrace
输入：任务接口、评价器、大语言模型、评价预算 B
建立虚拟根、空种群与尝试档案
当评价预算未耗尽且未满足停止条件时：
    若可行初始程序少于五个：
        构造初始化提示
    否则：
        采样父代与算子；需要时选择参考
        构造并适配对应的树上下文视图
    生成并评价程序，最多允许一次修复
    记录全部模型请求与评价结果
    若本次存在受评程序：
        接入最终受评版本；更新实际使用记录
        若初始化完成：
            在同一快照上选择质量代表与近期节点
            补入必要分叉祖先，确定最终保留集合
            在该快照上划分移除路径与旁支
            逐区域反思
            重连保留节点并附着对应经验
    提交本次尝试与对应种群更新
返回完整档案中搜索适应度最好的可行程序
```

每次更新保留当前最佳算法，并将每个保留节点重连到其最近保留祖先。两两分叉闭包使收缩路径互不重叠，其余移除节点各有唯一承接区域。附录 B 给出这些结构性质的论证。

4. 初步实验

我们在四个组合优化任务上检查实现，并报告一次冻结的早期搜索快照。快照来自 2026 年 11 月 14 日冻结源码的运行批次，包含每任务种子 0、1、2，共 12 路独立搜索。每路目标预算为 1000 次评价。快照时各路已完成 62–97 次评价。我们在共同的 60 次评价位置报告训练分数，并分析各路已提交前缀中的种群更新。独立测试与完整搜索比较需要使用完成后的运行结果。

4.1. 任务与评价条件

每个任务在固定求解器内演化一个函数。TSP 演化逐步构造中的下一节点选择；CVRP 与 OP 演化蚁群算法的边先验；FSSP 演化引导式局部搜索使用的矩阵与作业选择计算。目标依次为平均回路长度、平均路线长度、平均最大完工时间与负的平均收集奖励，均采用最小化约定。

每任务使用 16 个训练实例。50 个不重叠的同规模实例用于最终所选程序的测试。一次完整训练评价共享 160 秒时限，评价进程内存上限为 2 GiB，使用一个工作进程。失败消耗评价预算，修复重评单独计数。模型池提供关闭原生思考的 Qwen3.8-27B。生成温度为 1.0，输出上限 16384 词元；反思温度为 0.3，输出上限 1536 词元。其余任务与采样设置见附录 D。

搜索结束后先固定训练成绩最好的有效程序，再执行测试。测试结果不参与选择。模型请求及返回的词元用量与程序评价分别记账，从而区分经历压缩的模型成本和搜索评价预算。

4.2. 共同预算下的训练分数

表 1 报告 60 次评价后的训练最优分数。标准差为三路独立搜索之间的样本标准差。各任务保留原始计量单位；OP 最小化负奖励，因此越负越好。

表 1: 60 次评价后的训练最优值，越小越好。

任务	种子 0 / 1 / 2	均值	标准差
TSP	5.8774 / 5.9590 / 5.9229	5.9198	0.0409
CVRP	8.5584 / 8.6008 / 8.7791	8.6461	0.1171
FSSP	3880.31 / 3879.12 / 3892.25	3883.90	7.26
OP	-14.2787 / -14.5994 / -14.2663	-14.3815	0.1888

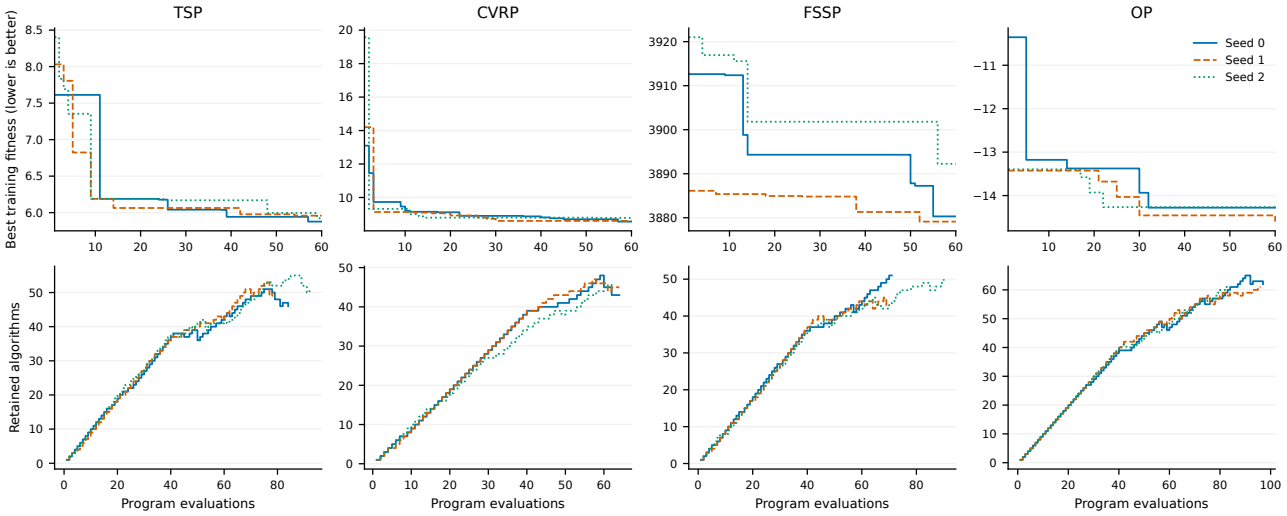


图 3: 冻结运行中的早期搜索。上排展示各任务三路搜索前 60 次评价的训练最优分数，采用共同可观察范围。下排按每次已提交受评入树及其对应移除重建保留算法数，延伸至各路观察终点，并与已保存的完整树快照核对。细线分别表示三个种子。这些轨迹描述当前阶段的搜索与种群维护过程。

4.3. 种群如何压缩历史

冻结前缀包含 951 次评价和 894 次已提交生成尝试。其中 207 次更新发生结构简化，将 286 个移除实现分配到 47 个路径区域和 175 个旁支区域。对已记录计划的核对确认，每个移除节点在相应更新中恰好归属一个区域。快照时各路保留 42–62 个算法；12 路共接入 894 个节点，其中 608 个仍为显式节点。相对 62–97 次评价的前缀，40 次评价的近期窗口占据相当大的范围。已记录区域以旁支为主（222 个中 175 个），因此早期简化主要体现为旁支凝练。

222 个区域产生 222 次模型反思，本快照没有回退摘要。186 个区域只包含一个本轮移除实现，最大区域包含五个。因此，压缩经常以增量方式进行：一次新的移除可以与载体上已积累的经验共同进入反思。本轮移除节点数描述当前更新，不等于摘要所代表的全部历史规模。

反思调用累计报告 505171 个输入词元与 29283 个输出词元。输入包括任务说明、端点代码、比较和继承经验，因此这两个数表示模型调用成本，其比值不衡量语义保留程度。这些记录确认了显式实现向节点和边经验的结构交接。附录 E 计划的固定状态对照将固定树快照、父代、算子和参考，只改变相同移除区域的表示方式，以检验经验对后续生成的作用。

5. 讨论

种群作为经历的表示。 EvoTrace 共同维护两种历史形式。保留程序可继续执行和开发；移除区域通过带有发展关系的摘要继续存在。后续更新再次改变这种表示，将旧经验交给新的节点或边。候选维护因而同时组织后续生成可以利用的经历。

增量压缩与保真度。区域规模表明，反思压缩经常通过连续的小规模更新累积，这使多轮交接中的摘要保真度成为重要变量。提示保留明确的比较结果、实际父代关系及观察与解释的区别，档案提供核对这些陈述所需的代码和评价。组合修改的解释对应被评价的整组变化；将结果归因于其中一个部件，需要额外比较。

研究范围。当前证据覆盖同一模型家族在四任务上的早期搜索，确认了结构简化与经验交接的运行过程。最终独立测试和受控历史读取对照将检验算法质量及压缩的作用。

6. 结论

EvoTrace 将候选竞争与设计经验积累联系起来。其出发点是区分实现的继续开发价值与经历的后续参考价值。树状种群使这一区分落实为算法：一次保留决策共同确定显式候选、压缩区域及经验承接位置。动态反思简化随种群变化继续交接摘要，算子视图将相关经验送入后续生成。由此，搜索状态同时保存可执行算法及其发展过程的凝练表示。

附录 A. 默认设置

组成	设置
初始化与评价预算	五个可行初始程序；1,000 次实际程序评价
近期保留	自身或同路线树上父代距出生或局部开发少于 40 次评价
质量代表	秩质量不低于 0.50，由优到劣检查；排除被同路线严格更优后代超越或已被覆盖的候选
覆盖距离	小于 0.08；适应度相差不超过 10^{-9} 时小于 0.20
父代采样	sigmoid 系数 10；按自身同路线开发次数折扣；路线最大权重与路线内归一化
算子先验	Refine 0.45；Crossover 0.25；Explore 0.30
参考资格	排除主父代与相同标准化源码后，秩质量不低于 0.30
路线视图筛选	入口标准化源码不同且 AST 距离不低于 0.12；按最新保留版本次序组织
演化生成输入	30,000 tokens，必要时按完整条目缩减
生成模型	温度 1.0，输出上限 16,384 tokens
反思模型	温度 0.3，输出上限 1,536 tokens；约 120 词的段落，证据少时更短

式（4）的尺度 s 为中位数绝对偏差（median absolute deviation, MAD），下限 10^{-6}。MAD 不超过 10^{-9} 时，使用大于 10^{-9} 的非零绝对偏差中位数，并保留同一下限。无非零偏差时使用尺度下限。实现以对数权重完成两级归一化；下溢的最终概率用最小正浮点值表示。参考池只有一个候选时，其秩质量为 1。

输入长度优先使用服务 tokenizer 计数。没有 tokenizer 的独立客户端以 UTF-8 字节数作为保守代理，并记录计数方式。输入适配用于三类演化生成提示；必要材料仍超窗时明确报错。

反思调用或解析失败时，系统使用 960 字符预算的确定性摘要，继续完成结构更新。完整区域输入和模型响应仍保存在档案中。连续十次尝试没有程序评价时，搜索提前停止。种群更新与产生它的尝试共同提交，恢复读取已提交更新，不重复调用对应反思。

$c(v)$ 统计以 v 为主父代的受评 Refine/Crossover 尝试，包括失败及后来被移除的尝试。同次尝试中的修复、Explore、只读参考、结构重连及继承历史不增加该计数。

附录 B. 单次更新的结构性质

设有限有根树中的保留集合 K 包含虚拟根、主动保留节点及这些节点两两之间的最近共同祖先。将每个非根保留节点重连到其最近保留祖先。

连通性与无环性。每个保留节点的祖先链按祖先关系全序排列，且包含虚拟根，因此最近保留祖先唯一。每条重连边严格沿原祖先链向上。持续沿边上行必然到达根，不能形成环，所得结构仍为 K 上的有根树。

收缩路径互不重叠。假设一个移除节点同时位于两条保留端点连接的内部。若两个后代端点在其下方分叉，其最近共同祖先位于重叠处且必须属于 K，与连接内部全部移除矛盾；若一个端点是另一个的祖先，前一个保留端点会截断后一条连接。因此，每个移除中间节点只属于一条收缩路径。

区域归属唯一。从全部移除节点中去掉收缩路径内部节点。其余每个节点沿祖先链向上，有唯一的首个不属于该剩余集合的祖先。这个祖先或者是路径中间节点，或者是保留节点，包括根。前者使该节点进入唯一的路径区域，后者使其进入该祖先的旁支区域。因此，每个移除节点在本轮更新中恰好被分配一次。该性质针对移除实现的归属；保留端点代码可以作为比较背景出现在多个反思输入中。

最优候选保留。代表选择首先纳入当前最佳可行节点，且不会再从代表集合移除它，因此它属于 K。这项性质描述当前种群；尝试档案独立保存最终选择所需的最佳可行程序。

以上性质描述结构及分配。语言摘要的具体内容由反思模型及输入证据决定。

附录 C. 反思提示模板

两类反思均先提供任务、接口和目标方向，再列出实现、代码差分、程序计算的结果标签、错误以及旧经验。英文稿附录 C 逐字收录实际任务与输出模板。核心要求如下。

路径反思。先陈述保留起点到终点的净结果，并共同描述计算变化。中间步骤和旁支只在提供额外信息时纳入，保留各自比较对象及结果标签。解释以 “一种可能的解释是” 引出，并限定于被测实现。Explore 表示新计算方向的初稿，其结果不代表整个方向的潜力。组合变化不能单独确定部件贡献。输出一个含 `experience` 字符串的 JSON 对象，通常不超过 120 个英文词。

旁支反思。每个尝试仅与其实际父代比较；无算法父代的初始实现不具有父代相对改进。先说明起始计算、整组修改及观察结果，再按证据给出可能解释。旧经验只有在比较对象与条件清楚时才继续保留。输出格式和长度约束与路径反思相同。

两类模板都要求以当前程序计算的比较为准，区分整段净变化与中间变化，避免从同分推导程序等价，也不将经验写成未来设计指令。模板原文保存在 `evotrace_v2/reflection.py`。

附录 D. 复现与记账

当前部署在启动前冻结方法源码、任务定义、评价器和采样配置。每条已提交尝试记录生成程序、含修复在内的全部评价、父代与参考编号、上下文视图及种群更新。更新记录包括移除区域、反思响应和结果树。恢复重放已提交更新，不重复请求反思。一次尝试的最终受评版本进入在线树，修复前版本保存在尝试档案中。

搜索种子为 0、1、2。TSP 训练使用 50 节点欧氏实例，数据种子 2024。CVRP 使用 30 只蚂蚁、100 轮 ACO 迭代；OP 使用 20 只蚂蚁、50 轮迭代；两项 ACO 任务的求解器种子均为 1234。训练评价种子为 730241。冻结任务配置完整规定 FSSP 实例与求解器设置。生成提示提供接口与目标；实例数量、数据划分和求解器迭代次数属于评价条件。

生成采样另设 top-p 为 0.8、top-k 为 20、presence penalty 为 1.5。公共模型池在多个端点间分配调用，返回的模型名包括 `Qwen3.8-27B` 和 `qwen3.8-27b-awq`。端点名称本身不能证明数值推理完全一致。每次调用的元数据记录端点及返回用量。服务接口故障与候选执行失败分别记账。

交付的证据快照保存每路来源路径、已提交尝试文件的 SHA-256、捕获时间、不含凭据的配置及第 4 节使用的精确评价前缀。分数表和图 3 由快照生成。更新快照需要显式执行；重新编译论文不会刷新实验数据。

附录 E. 核心主张的评价设计

以下方案规定后续检验，第 4 节报告的是已观察到的部署快照。

完整搜索。冻结各比较方法后，每任务运行三个搜索种子。对齐任务接口、数据、候选评价限制、生成设置、评价记

账和最终选择。原方法若按生成而非评价计数，单独记录其预算定义。报告训练轨迹、按训练选定程序的测试分数、逐种子值、失败，以及生成、修复和反思成本。

固定状态的历史表示。从预先指定的评价位置抽取状态，不按后续成功挑选。固定父代、算子、参考、当前代码及任务说明，比较省略历史、相同区域原始材料及实际反思摘要。每条件重复采样，以快照为配对单位，同一快照生成的多个后代不作为独立搜索路次。按任务及算子报告分数、执行成功、父代相对改进及输入词元；超过窗口的原始历史单列。

经验位置。固定所选摘要与输入预算，比较原有结构组织和保留来源标签的共享列表，区分结构分组与文本可用性各自的作用。

摘要保真度。按任务、区域类型与既往交接次数记录随机抽样。比较方向与评价档案核对，计算描述与实际代码核对，分别记录结果、代码描述和解释的错误。后续提示是否读到经验单独追踪，不直接等同于经验造成改进。

参考文献

Edmund K Burke, Michel Gendreau, Matthew Hyde, Graham Kendall, Gabriela Ochoa, Ender Özcan, and Rong Qu. Hyper-heuristics: a survey of the state of the art. *Journal of the Operational Research Society*, 64(12): 1695–1724, 2013. doi: 10.1057/jors.2013.71. URL https://doi.org/10.1057/jors.2013.71.

Pham Vu Tuan Dat, Long Doan, and Huynh Thi Thanh Binh. Hsevo: Elevating automatic heuristic design with diversity-driven harmony search and genetic algorithm using llms. *Proceedings of the AAAI Conference on Artificial Intelligence*, 39(25):26931–26938, 2025. doi: 10.1609/aaai.v39i25.34898. URL https://doi.org/10.1609/aaai.v39i25.34898.

Oguzhan Gungordu, Siheng Xiong, and Faramarz Fekri. PathWise: Planning through world model for automated heuristic design via self-evolving LLMs. In *Proceedings of the 43rd International Conference on Machine Learning*, volume 306, pages 37779–37816. PMLR, 2026. URL https://proceedings.mlr.press/v306/gungordu26a.html.

Fatemeh Haji, Javier Delarosa Quiros, and Peyman Najafirad. Memory-guided tree search with cross-branch knowledge transfer for llm solver synthesis, 2026. URL https://arxiv.org/abs/2605.17539.

Qinglong Hu and Qingfu Zhang. Partition to evolve: Niching-enhanced evolution with llms for automated algorithm discovery. In *Advances in Neural Information Processing Systems*, volume 38, Main Conference, pages 154771–154817. Curran Associates, Inc., 2025. doi: 10.52202/085713-5177. URL https://papers.nips.cc/paper_files/paper/2025/hash/e389b15166cf98966ba058965a8c17e3-Abstract-Conference.html.

Jiachen Jiang, Tianyu Ding, and Zhihui Zhu. Deltaevolve: Accelerating scientific discovery through momentum-driven evolution, 2026. URL https://arxiv.org/abs/2602.02919.

John R. Koza. Genetic programming as a means for programming computers by natural selection. *Statistics and Computing*, 4(2), 1994. doi: 10.1007/bf00175355. URL https://doi.org/10.1007/bf00175355.

Kezhao Lai, Yutao Lai, and Hai-Lin Liu. Beyond the node: Clade-level selection for efficient mcts in automatic heuristic design, 2026. URL https://arxiv.org/abs/2602.00549.

Robert Lange, Yuki Imajuku, and Edoardo Cetin. Shinkaevolve: Towards open-ended and sample-efficient program evolution. In *International Conference on Learning Representations*, volume 2026, pages 74026–74078, 2026. URL https://proceedings.iclr.cc/paper_files/paper/2026/hash/7886b9bafe76c52fd568db10ff9772df-Abstract-Conference.html.

Joel Lehman, Jonathan Gordon, Shawn Jain, Kamal Ndousse, Cathy Yeh, and Kenneth O. Stanley. Evolution through large models, 2022. URL https://arxiv.org/abs/2206.08896.

Fei Liu, Xialiang Tong, Mingxuan Yuan, Xi Lin, Fu Luo, Zhenkun Wang, Zhichao Lu, and Qingfu Zhang. Evolution of heuristics: Towards efficient automatic algorithm design using large language model. In *Proceedings of the 41st International Conference on Machine Learning*, volume 235, pages 32201–32223. PMLR, 2024. URL https://proceedings.mlr.press/v235/liu24bs.html.

Fei Liu, Yiming Yao, Ping Guo, Zhiyuan Yang, Xi Lin, Zhe Zhao, Xialiang Tong, Kun Mao, Zhichao Lu, Zhenkun Wang, Mingxuan Yuan, and Qingfu Zhang. A systematic survey on large language models for algorithm design. *ACM Computing Surveys*, 58(8):1–32, 2026. doi: 10.1145/3787585. URL https://doi.org/10.1145/3787585.

Manuel López-Ibáñez, Jérémie Dubois-Lacoste, Leslie Pérez Cáceres, Mauro Birattari, and Thomas Stützle. The irace package: Iterated racing for automatic algorithm configuration. *Operations Research Perspectives*, 3:43–58, 2016. doi: 10.1016/j.orp.2016.09.002. URL https://doi.org/10.1016/j.orp.2016.09.002.

Aman Madaan, Niket Tandon, Prakhar Gupta, Skyler Hallinan, Luyu Gao, Sarah Wiegreffe, Uri Alon, Nouha Dziri, Shrimai Prabhumoye, Yiming Yang, Shashank Gupta, Bodhisattwa Prasad Majumder, Katherine Hermann, Sean Welleck, Amir Yazdanbakhsh, and Peter Clark. Self-refine: Iterative refinement with self-feedback. In *Advances in Neural Information Processing Systems*, volume 36, pages 46534–46594. Curran Associates, Inc., 2023. doi: 10.52202/075280-2019. URL https://proceedings.neurips.cc/paper_files/paper/2023/hash/91edff07232fb1b55a505a9e9f6c0ff3-Abstract-Conference.html.

Elliot Meyerson, Mark J. Nelson, Herbie Bradley, Adam Gaier, Arash Moradi, Amy K. Hoover, and Joel Lehman. Language model crossover: Variation through few-shot prompting. *ACM Transactions on Evolutionary Learning and Optimization*, 4(4):1–40, 2024. doi: 10.1145/3694791. URL https://doi.org/10.1145/3694791.

Alexander Novikov, Ngân Vũ, Marvin Eisenberger, Emilien Dupont, Po-Sen Huang, Adam Zsolt Wagner, Sergey Shirobokov, Borislav Kozlovskii, Francisco J. R. Ruiz, Abbas Mehrabian, M. Pawan Kumar, Abigail See, Swarat Chaudhuri, George Holland, Alex Davies, Sebastian Nowozin, Pushmeet Kohli, and Matej Balog. Alphaevolve: A coding agent for scientific and algorithmic discovery, 2025. URL https://arxiv.org/abs/2506.13131.

Zishang Qiu, Xinan Chen, Rong Qu, and Ruibin Bai. Meevo: Metacognitive evolution combined with natural evolution for automatic heuristic design, 2026. URL https://arxiv.org/abs/2606.14202.

Bernardino Romera-Paredes, Mohammadamin Barekatain, Alexander Novikov, Matej Balog, M. Pawan Kumar, Emilien Dupont, Francisco J. R. Ruiz, Jordan S. Ellenberg, Pengming Wang, Omar Fawzi, Pushmeet Kohli, and Alhussein Fawzi. Mathematical discoveries from program search with large language models. *Nature*, 625 (7995):468–475, 2024. doi: 10.1038/s41586-023-06924-6. URL https://www.nature.com/articles/s41586-023-06924-6.

Noah Shinn, Federico Cassano, Ashwin Gopinath, Karthik Narasimhan, and Shunyu Yao. Reflexion: language agents with verbal reinforcement learning. In *Advances in Neural Information Processing Systems*, volume 36, pages 8634–8652. Curran Associates, Inc., 2023. doi: 10.52202/075280-0377. URL https://proceedings.neurips.cc/paper_files/paper/2023/hash/1b44b878bb782e6954cd888628510e90-Abstract-Conference.html.

Niki van Stein and Thomas Bäck. Llamea: A large language model evolutionary algorithm for automatically generating metaheuristics, 2025. URL https://arxiv.org/abs/2405.20132.

Yang Wu, Junran Pan, Yifan Zhang, Ning Xu, Fanshuo Zeng, and Jian Cheng. Refineevo: Planning-guided heuristic evolution with bidirectional experience, 2026. URL https://arxiv.org/abs/2607.11358.

Haoran Ye, Jiarui Wang, Zhiguang Cao, Federico Berto, Chuanbo Hua, Haeyeon Kim, Jinkyoo Park, and Guojie Song. Reevo: Large language models as hyper-heuristics with reflective evolution. In *Advances in Neural Information Processing Systems*, volume 37, pages 43571–43608. Curran Associates, Inc., 2024. doi: 10.5

2202/079017-1381. URL https://papers.nips.cc/paper/2024/hash/4ced59d480e07d290b6f29fc8798f195-Abstract-Conference.html.

Andrew Zhao, Daniel Huang, Quentin Xu, Matthieu Lin, Yong-Jin Liu, and Gao Huang. Expel: Llm agents are experiential learners. *Proceedings of the AAAI Conference on Artificial Intelligence*, 38(17):19632–19642, 2024. doi: 10.1609/aaai.v38i17.29936. URL https://ojs.aaai.org/index.php/AAAI/article/view/29936.

Leyi Zhao, Weijie Huang, Yitong Guo, Jiang Bian, Chenghong Wang, and Xuhong Zhang. Large language model-powered evolutionary code optimization on a phylogenetic tree, 2026. URL https://arxiv.org/abs/2601.14523.

Zhi Zheng, Zhuoliang Xie, Zhenkun Wang, and Bryan Hooi. Monte Carlo tree search for comprehensive exploration in LLM-based automatic heuristic design. In *Proceedings of the 42nd International Conference on Machine Learning*, volume 267, pages 78338–78373. PMLR, 2025. URL https://proceedings.mlr.press/v267/zheng25o.html.